数据结构与算法第9章文件管理和外排序

主要内容



- □91 主存储器和外存储器
- □9.2 文件的组织和管理
- □9.3 外排序
- □94 文件管理和外排序知识点总结



9.1 主存储器和外存储器



□ 计算机存储器主要有两种:

- 主存储器(primary memory或者main memory, 简 称"内存",或者"主存")
 - 随机访问存储器(Random Access Memory, 即RAM)
 - 高速缓存(cache)
 - 视频存储器(video memory)
- 外存储器(peripheral storage或者secondary storage, 简称"外存")
 - 硬盘
 - 软盘
 - 磁带



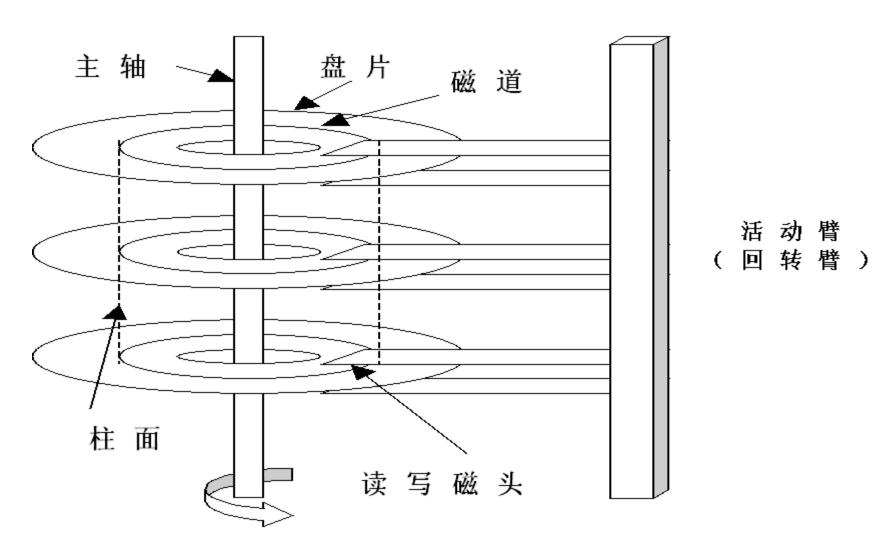
外存的优缺点



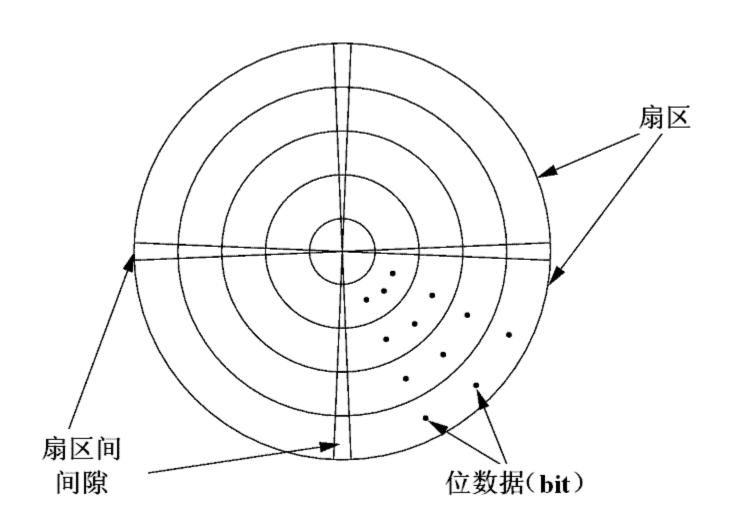
- □优点:价格低、信息不易失、便携性
- □缺点: 存取速度慢
 - 一般的内存访问存取时间的单位是纳秒(1纳秒 = 10-9 秒),而外存一次访问时间则以毫秒(1毫秒 = 10-3秒)或秒为数 量级。
- □ 牵扯到外存的计算机程序应当尽量减少外存的访问 和存取次数. 从而减少程序执行的时间



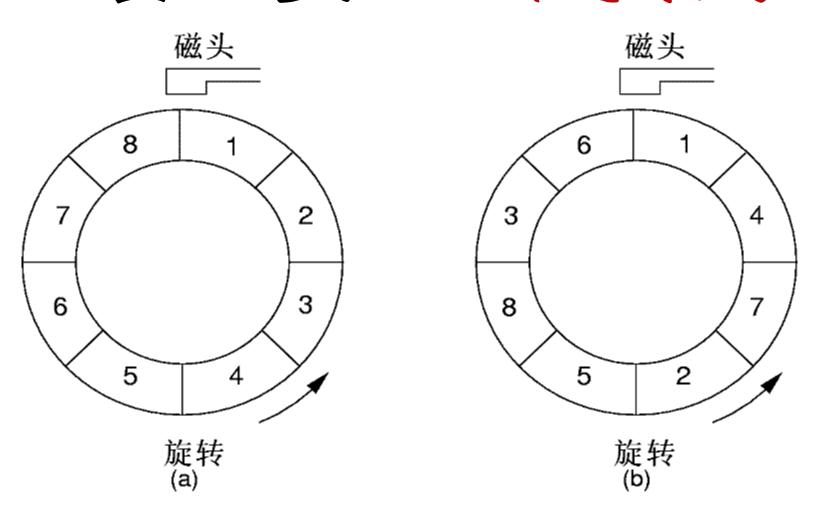
磁盘的物理结构



磁盘盘片的组织



磁盘磁道的组织(交错法)



(a) 没有扇区交错; (b) 以3为交错因子

磁盘存取步骤



- ■选定某个盘片组
- ■选定某个柱面
 - 这需要把磁头移动到该柱面,这个移动过程 称为寻道(seek)
- ■确定磁道
- ■确定所要读写的数据在磁盘上的准确位置
 - 这段时间一般称为旋转延迟(rotational delay 或者rotational latency)
- ■真正进行读写



内存的优缺点



□优点:访问速度快

□缺点:造价高、存储容量小和断电后丢

失数据

□CPU直接与主存沟通,对存储在内存地 址的数据进行访问时。所需要的时间可 以看作是一个很小的常数



外存数据访问方式



- □外存空间被划分成长度固定的存储块, 称为页(page),每一页包含一定数量的 数据单元
- □作为外存的基本存储单位,数据以页块 为单位进行存取,这样可以减少外存的 定位次数. 从而减少外存读写的时间耗 费



- □ 文件(file)是存储在外存上的数据结构。是由 大量性质相同的记录(record)组成的集合。
- □所谓记录, 就是具有独立逻辑意义的数据块, 是文件的基本数据单位。
- □最简单的记录可以是字符或者二进制序列,复 杂的记录通常可以由若干字段或域(field)的数 据项组成。





按照记录的类型。文件可以分成两种:

□ 操作系统的文件

操作系统的文件是一组连续的字符序列,这种序列没 有明显的结构。用户也可以将文件中的信息划分成若 干个逻辑记录, 以便存取和使用。

□数据库文件

数据库文件是有结构的记录集合,其中每一条记录都 由一个或多个数据项组成,而每个数据项是不可再分 的基本数据单元。



如表9.1所示为一个数据库文件, 每个学生的信息组 成一个记录,每一条记录由6个数据项构成。

姓名	学号	性别	出生年月	所在院系	入学时间
贾由	00646125	男	1988.5	数学	2006.9.1
陈醒	00648308	男	1989.7	计算机	2006.9.1
吴轲	00648230	男	1988.3	计算机	2006.9.1
王子琪	00648139	女	1988.2	计算机	2006.9.1
	•••••	• • • • •	••••	••••	••••





按照记录信息长度. 文件可以分成

□定长文件

如果文件中每一条记录均含有相同的信息长 度, 那么这种文件称为定长文件。通常定长文 件处理起来比较方便。

□不定长文件

若文件中的记录不是相等长度的,则称为不定 长文件。





按照关键码(key)的个数, 文件可以分成:

□单关键码文件

单关键码文件是指文件的记录中只有一个标识关 键码

□多关键码文件

多关键码记录文件中,记录除了有一个主关键码 以外还允许有若干个次关键码





□文件的操作有实时和批量两种处理

方式

- 实时操作要求有较短的应答响应时间,在接受指 令后尽可能快地完成检索或修改任务。
- 批量的文件处理则允许较长反馈时间。用户可以 根据需求选择不同的文件处理方式。





□9.2.1 文件组织

□9.2.2 C++的流文件



9.2.1 文件组织



- □文件逻辑组织有以下三种形式:顺序结 构的定长记录、顺序结构的变长记录和 按关键码存取的记录。
- □文件的物理结构可以有多种多样的组织 方式。常见的物理组织结构有:
 - ■顺序文件
 - ■散列文件
 - ■索引文件
 - ■倒排文件





- □文件流是以外存文件为输入输出对象的数 据流。
- □文件流与文件不是同一个概念。文件流不 是由若干个文件组成的流。文件流本身不 是文件. 而只是以文件为输入输出对象的 流。





- □标准输入输出流类包括istream, ostream和iostream类
 - istream是通用输入流和其它输入流的基类,支持输入
 - ostream是通用输出流和其它输出流的基类,支持输出
 - iostream是通用输入输出流和其它输入输出流的基类,支持输入输出

□3个用于文件操作的文件类

- ifstream类,从istream类派生,用来支持从磁盘文件的输入
- ofstream类,从ostream类派生,用来支持向磁盘文件的输出
- fstream类,从iostream类派生,用来支持对磁盘文件的输入

十一五"国家级规划教材。张铭,王腾蛟,赵海薰,《数据结构与算法》,高教社,2008.6。





下面是fstream类的一些主要成员函数:

```
#include <fstream.h>
                         // fstream = ifstream+ofstream
void fstream::open(char*name, openmode mode); // 打开文件进行处理
fstream::read(char*ptr, int numbytes); // 从文件当前位置读入一些字节
fstream::write(char*ptr, int numbtyes); // 向文件当前位置写入一些字节
// seekg和seekp: 在文件中移动当前位置, 以便在文件中的任何位置读
  出或写入字节
fstream::seekg(int pos);
                           // 输入时用于设置读取位置
fstream::seekg(int pos, ios::curr);
fstream::seekp(int pos);
                           // 设置输出时的写入位置
fstream::seekp(int pos, ios::end);
void fstream::close();
                           // 处理结束后关闭文件
```





文件常见的三个基本操作:

- □ 把文件指针设置到指定位置
- □从文件的当前位置读取字节
- □向文件中的当前位置写入字节,都是围绕文件 指针进行的
- 程序员对磁盘文件进行输入输出时,都需要管理标志 文件当前位置的文件指针。





- □9.3.1 置换选择排序
- □9.3.2 二路外排序
- □9.3.3 多路归并——选择树





- □如果数据存放在外存文件中,则需要考虑外存 特点,采用外存文件排序技术。 简称外排序 (external sort).
- □需要根据内存的大小. 将外存中的数据文件划 分成若干段. 每次把其中一段读入内存并用内 排序方法进行排序。这些已排序的段或有序的 子文件称为顺串或归并段(run)。





- □ 外排序通常由两个相对独立的阶段组成:
 - 文件形成尽可能长的初始顺串
 - 逐趟归并顺串,最后形成对整个数据文件的排列文件
- □ 外排序所需要的时间由三部分组成:
 - ■内部排序所需要的时间
 - ■外存信息读写所需要的时间
 - ■内部归并所需要的时间
- □減少外存信息的读写次数是提高外部排序效率的关键

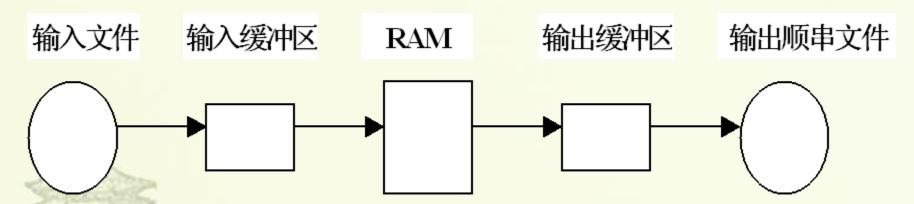




- □对同一个文件而言,进行外排序所需读写外存的 次数与归并趟数有关系
- □ 假设有m个初始顺串。每次对k个顺串进行归并。 归并趟数为[logkm]
- □ 为了减少归并趟数, 可以从两个方面着手:
 - ■减少初始顺串的个数m
 - ■增加归并的顺串数量k







□算法的处理过程为:从输入文件读取一定数量 的记录进入输入缓冲区: 然后向内存工作区放 入待排序记录并进行排序;记录被处理后。写 到输出缓冲区: 当输出缓冲区写满的时候。把 整个缓冲区写回到外存文件。当输入缓冲区为 空时, 再次从外存文件中读取下一块记录。





置换选择产生一个顺串的算法如下:

- 1、初始化堆:
 - (1) 从磁盘读M个记录放到数组RAM中;
 - (2) 设置堆尾指标LAST = M 1;
 - (3) 建立一个最小堆。
- 2、重复以下步骤,直到堆为空(即LAST < 0):
 - (1) 把具有最小关键码值的记录(根结点)送到输出缓冲区;





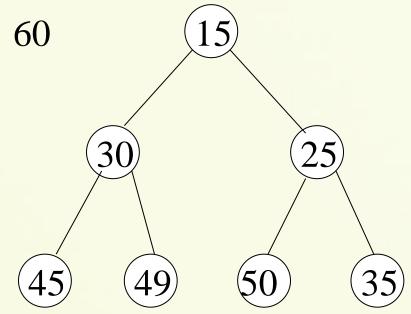
- (2) 设R是输入缓冲区中的下一条记录。判断R的关键码值是否大于刚刚输出的关键码值,
 - ① 如果是,那么把R放到根结点。
 - ② 否则,
 - (a) 使用数组中LAST位置的记录代替根结点;
 - (b) 把R放到LAST位置;
 - (c) 设置LAST = LAST 1。
- (3) 重新排列堆, 筛出根结点。





置换选择示例

27 16







【算法9.1】 置换选择算法

```
// 参数A是从外存读入数据后所存放的数组, n是数组元素
  的个数, in和out是输入和输出文件名
template<class T>
void replacementSelection(T *A, int n, const char *in, const
  char*out) {
  T mval;
                           // 存放最小堆的最小值
                // 存放从输入缓冲区中读入的元素
  Tr;
  FILE *inputFile;
                                 // 输入文件句柄
  FILE *outputFile;
                                 // 输出文件包柄
  Buffer<T> input;
                                 // 输入缓冲区
  Buffer<T> output;
                                 // 输出缓冲区
  initFiles(inputFile, outputFile, in, out);
                                 // 初始化输入输
  出文件
```



```
initMinHeapArry(inputFile, n, A);
// 从输入文件读入n个数据初始化堆数组A
MinHeap<T>H(A, n);
                                     // 建立最小堆
initInputBuffer(input, inputFile);
// 初始化输入缓冲区, 读入一部分数据
for (int last = (n-1); last >= 0;) {
                                           // 堆不
为空
    mval = H.heapArray[0]; // 获得堆的最小值
    sendToOutputBuffer(input, output, inputFile,
outputFile, mval); // 把mval送到输出缓冲区
    input.read(r);
                              // 从输入缓冲区读入
一个记录r
    if (!less(r, mval)) {
//如果r值大于等于输出值, r放到堆的根结点
          H.heapArray[0] = r;
```

"十一五"因家级规划教材。社铭,王腾蛟,赵海薰,《数据结构与算法》,高教社,2008.6。

```
else {
                                //r不能入堆
            H.heapArray[0] = H.heapArray[last];
      // 用堆中last位置的记录代替根结点
            H.heapArray[last] = r;// 把r放到last位置
            H.setSize(last);
                                      // 堆规模减小1
last--;
                                             // 设置
  LAST = LAST - 1
      if (last != 0) {
                                // 重新排列堆
            H.SiftDown(0); // 从根结点开始向下筛选
  endUp(output, inputFile, outputFile);输出缓冲区,关闭输入和输出文件
                                             // 处理
```

小学小岛



置换选择排序算法得到的顺串长度并不 相等。平均情况下. 置换选择排序算法 可以形成长度为2M的顺串。



9.3.2 二路外排序



处理方法:即首先把数据文件划分成若干 段. 用有效的内排序方法对文件的各段进 行初始排序以形成顺串: 然后把这些顺串 逐趟合并, 直至变为一个顺串为止。



9.3.2 二路外排序



第一趟归并

第二趟归并

第三趟归并

第四趟归并

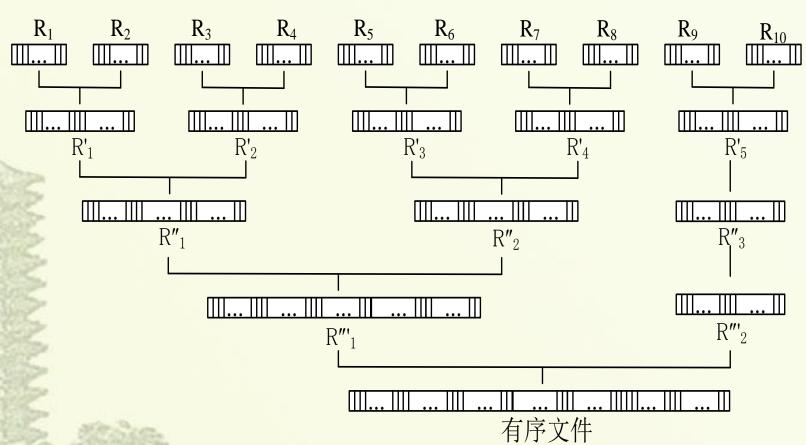


图 9.3 二路归并过程



9.3.2 二路外排序



- □为一个待排文件创建尽可能大的初始顺 串. 可以大大減少扫描遍数和外存读写 次数。
- □归并顺序的安排也能影响读写次数。把 初始顺串长度作为权, 其实质就是 Huffman树最优化问题。



9.3.3 多路归并——选择树



- □k路归并是每次将k个顺串合并成一个排 好序的顺串。一般情况下,对m个初始 顺串进行k路归并时归并趟数为log,m。 增加每次归并的顺串数量水可以减少归并 趟数。
- □选择树是完全二叉树. 有两种类型: 赢 者树和败者树。





- □假设用完全二叉树的公式化描述方法来定 义赢者树. 采用数组作为存储结构。
 - 选手或叶结点用数组L[1...n]表示,内部结点用数组 B[1...n-1]表示
 - ■数组B中实际存放的是数组L的索引
- □赢者树的一个优点是。如果一个选手L[i] 的分数值改变了,可以很容易地修改这棵 赢者树。只需要沿着从L[i]到根结点的路 径修改二叉树, 而不必改变其它比赛的结 果。





【代码9.2】 赢者树的类定义

```
template<class T>
class WinnerTree {
private:
 int MaxSize; // 最大选手数
 int n;
       // 当前选手数
 int LowExt; // 最底层外部结点数
 int offset;
          // 最底层外部结点之上的结点总数
 int *B;
          // 赢者树数组. 存储数组L的索引
 T *L;
               // 叶结点数组
```





```
// 在内部结点B[p]处开始从右分支向上比赛
  void Play(int p, int lc, int rc, int(*winner)(T A[], int b, int
  c));
public:
  WinnerTree(int Treesize = MAX);
                   // 构造函数
  ~WinnerTree(){delete [] B;}
                   // 析构函数
  void Initialize(T A[], int size,int (*winner)(T A[], int b, int
  c)); // 初始化赢者树
  int Winner();
                                    // 返回最终胜者的
  索引
  void RePlay(int i, int(*winner)(T A[], int b, int c));
             // 外部L[i]改变后重构赢者树
```

教材。张铭,王腾蛟,赵海燕,《数据结构与算法》,高教社,2008.6。

北京小学



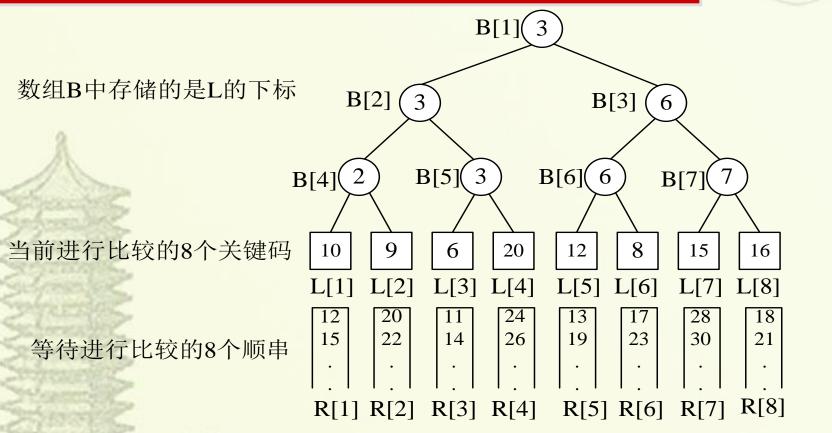


图9.5 8路合并的赢者树





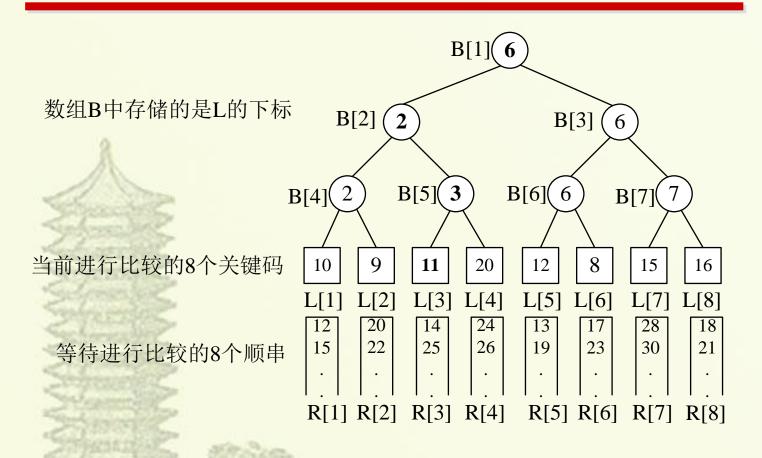


图9.6 重构后的赢者树





- □败者树是赢者树的一种变体。在败者树 中. 用父结点记录其左右子结点进行比 赛的败者。而让获胜者去参加更高阶段 的比赛。
- □另外,根结点处加入一个结点来记录整 个比赛的胜者。
- □采用败者树是为了简化重构的过程。





重构过程如下:

- □将新进入选择树的结点与其父结点进行 比赛
 - 把败者的下标存放在父结点中
 - ■而胜者再与上一级的父结点比较
- □比赛沿着到根结点的路径不断进行。直 到结点B[1]处
 - 把败者的索引放在结点B[1]
 - 把胜者的索引放到结点B[0]





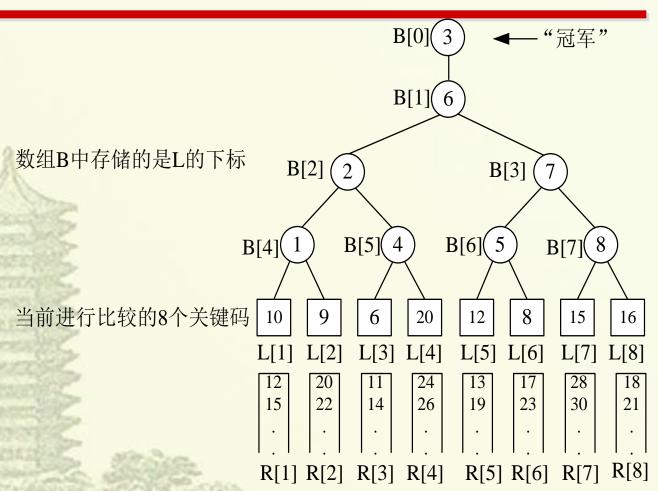


图 9.7 8路合并的败者树示例

五"国家级规划教材。张铭,王腾蛟,赵海遵,《数据结构与算法》,高教社,2008.6。





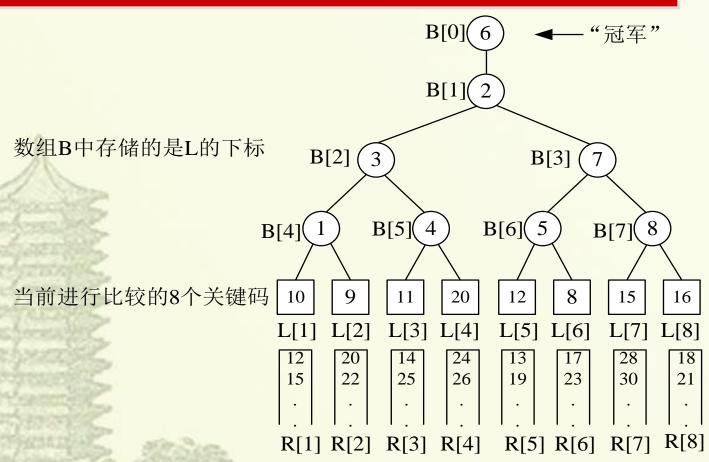


图 9.8 重构后的 8路合并败者树

小学小诗



- □利用败者树实现多路归并排序算法,首 先初始化一棵败者树,取得最终胜者的 索引。
 - 把胜者送入输出缓冲区中,如缓冲区已满,就把输出缓冲区的数据传输到磁盘文件中
 - 然后再从输入缓冲区中读入一个新的关键码,重 新从叶结点到根结点调整败者树选择下一个胜者
 - 如果输入缓冲区为空,则从输入文件读取一批数据进输入缓冲区;如果对应输入文件已经没有数据了(本顺串数据处理完毕),就在新的竞赛者位置置入一个较大的数



多路归并的效率



假设对k个顺串进行归并:

- □原始方法:找到每一个最小值的时间是O(k),产 生一个大小为n的顺串的时间复杂度是()(k·n)
- □ 败者树方法: 对k个顺串进行归并, 初始化包含 k个选手的败者树, 需要时间O(k), 把最小值输 出到缓冲区后。读入一个新值并重构败者树的 时间为 $O(\log k)$,那么产生一个大小为n的顺串的 总时间缩短为O(k+n·log k), 近似于O(n·log k)
- □显然败者树归并效率更高



9.4 文件管理和外排序知识点总结

- □主存储器和外存储器的特点
- □文件的组织形式
- □外排序思想
- □置换选择排序
- □二路外排序
- □选择树 (赢者树和败者树)





The End

